

Pipeline DataOps para predicción de churn en telecomunicaciones

Evaluación Parcial N°2 · ITY1101 Gestión de Datos para IA · Sección 003V

☁ Cloud-native

🔗 Pipeline 4 etapas

🗄 Supabase + Railway

Benjamín Heresmann

Ingeniero de Datos

ingesta · validación · arquitectura

Diego Hernández

Ingeniero de BD / DataOps

limpieza · carga · seguridad · deploy

Caso: Telco Customer Churn · Entrega: 2 de junio de 2026

Qué veremos

1. El problema y la necesidad
2. DataOps vs. enfoque tradicional
3. Arquitectura cloud desacoplada
4. Ciclo de vida del dato (pipeline)
5. Metodología y planificación
6. Las 4 etapas del pipeline
7. Plan de seguridad y KPIs
8. **Demo funcional en vivo**
9. Conclusiones y próximos pasos
10. Preguntas

15 min presentación

demo en vivo

5 min preguntas

El problema: la fuga de clientes

- Una telco pierde clientes (**churn**) cada mes.
- Captar uno nuevo cuesta **mucho más** que retener uno.
- Para retener hay que **anticipar** quién se va a ir.
- Anticipar exige **datos limpios, confiables y trazables**.

Sin datos de calidad no hay modelo de IA que funcione: el pipeline es el cimiento.

26,5%

TASA DE CHURN EN EL DATASET

1.869 de **7.043** clientes abandonaron.


Cada uno = ingresos recurrentes perdidos.

¿Por qué DataOps y no el enfoque tradicional?

Dimensión	Enfoque tradicional	DataOps (nuestro proyecto)
Procesamiento	Excel manual, copy-paste	Scripts automatizados (4 etapas)
Errores	Invisibles, se detectan tarde	Validación explícita + registro de rechazos
Reproducibilidad	"Funciona en mi PC"	Docker + carga idempotente
Trazabilidad	Sin historial	Cada ejecución auditada en BD
Despliegue	Local, frágil	Cloud (Railway + Supabase), API pública


DataOps = sistema reproducible, observable y colaborativo — no solo "correr un script".

Arquitectura cloud desacoplada no monolito



Tres servicios independientes: si Railway cae, la BD sigue; se escala la API sin tocar los datos.

El pipeline: 4 etapas desacopladas



Cada etapa es un **endpoint REST independiente**:

- `POST /pipeline/ingest`
- `POST /pipeline/clean`
- `POST /pipeline/validate`
- `POST /pipeline/load`
- `POST /pipeline/run` — orquesta las 4

Si una etapa falla, las anteriores ya dejaron su salida persistida → se retoma desde ahí.

PMBOK híbrido (predictivo + adaptativo)

Predictivo

Requisitos fijos, dependencias claras

- Modelo de BD y DDL
- Esquema de validación
- Dockerfile e integración

→ cronograma, hitos, Carta Gantt

Adaptativo


Exploratorio, iterativo

- Reglas de validación semántica
- Afinamiento de KPIs
- Ensayo de la demo

→ ciclos cortos, revisión cruzada

Cascada pura sería rígida; ágil pura, caótica para las dependencias. El híbrido **planifica lo estable e itera lo incierto**. Seguimiento con **Trello**.

WBS y Carta Gantt



1 Ingesta

- **Qué hace:** captura el CSV fuente y lo deposita en `data/raw/` con sello temporal, sin transformarlo.
- **Herramienta:** Python (`shutil` + `pandas`), logging con conteo de filas.

✓ Decisión técnica

Ingesta por lotes (batch), no streaming: el dato es un CSV estático → Kafka sería sobreingeniería.

Dataset **versionado en el repo** → reproducible y sin dependencias externas en la demo.

2

Limpieza y transformación

- **Bug clásico resuelto:** `TotalCharges` venía como texto con vacíos → a numérico, imputando 0 a clientes con `tenure=0`.
- Yes/No → booleano.
- Feature derivada `tenure_group` (5 rangos).
- Eliminación de duplicados por `customerID`.

✓ Principio

Se trabaja sobre **copia**, nunca sobre el crudo. La limpieza **normaliza**; no decide qué es válido (eso es la etapa 3).

3

Validación estructural y semántica

✓ Estructural — `pandera`

- Tipos por columna
- Rangos (`tenure` 0–100)
- Valores permitidos
- Regex de `customerID`

✓ Semántica — reglas de negocio

- Si `InternetService=No` → servicios = "No internet service"
- `PhoneService` ↔ `MultipleLines`
- Coherencia de `TotalCharges`

Válidos → `data/validated/`. Inválidos → `data/rejected/` **con su motivo**, auditados en la tabla `clientes_rechazados`.

4

Carga a base de datos

- Persiste en **Supabase PostgreSQL** (SQLAlchemy + SSL).
- **Full-refresh idempotente:** `TRUNCATE` + insert en una transacción → reejecutar da siempre el mismo estado.
- Atómico: ante fallo, `ROLLBACK`.
- Auditoría en `carga_logs` (nunca se trunca).

⚠ Manejo de anomalías

Conexión caída → estado "ERROR" en log · violación de constraint → rollback · inválidos → separados y auditados, nunca descartados en silencio.

Seguridad: legal + técnica

⚖️ Normas legales

- **Ley 19.628** — datos personales (Chile)
- **Ley 21.459** — delitos informáticos
- Tratamiento limitado al propósito

🛡️ Técnicas

- Cifrado en tránsito (SSL a la BD)
- Control de acceso (rol solo-SELECT)
- Secretos en variables de entorno
- Anti-inyección (SQL parametrizado)

🔒 enmascaramiento

🛡️ control de acceso

🔒 cifrado

☰ auditoría

KPIs del pipeline

KPI	Umbral de alerta
Latencia total	> 30 s
Tasa de validez	< 95%
Complejidad por columna	< 95%
Volumen procesado	< 5.000
Estado de ejecución	≠ OK

Consultables en vivo


Persistidos en `carga_logs` y expuestos por la API:

`GET /kpis/resumen`

`GET /kpis/last`

En producción → Grafana / alertas.

Demo: pipeline en producción



Ejecutamos `POST /pipeline/run` → carga 7.043 clientes en Supabase · luego `GET /kpis/resumen` y `GET /rechazados` .

Conclusiones y próximos pasos

✓ Lo logrado

- Pipeline DataOps de 4 etapas, **reproducible y trazable**.
- Desplegado en la nube, **no monolítico**.
- Probado end-to-end + CI verde.

→ Próximos pasos

- **Evaluación 3:** modelo de clasificación sobre `churn`.
- Variables clave: `tenure`, `Contract`, `MonthlyCharges`.
- Orquestación (Airflow) y dashboard de KPIs.

La tabla `clientes` en Supabase ya queda lista como fuente de entrenamiento para el modelo de IA.

¡Gracias!

¿Preguntas?

 github.com/BenjaminHeresmann/telco-churn-pipeline

 telco-api-production-e466.up.railway.app/docs

Benjamín Heresmann · Diego Hernández — Sección 003V · ITY1101 Duoc UC